

Universidad EAFIT

Curso: Aprendizaje de Máquina Aplicado

Taller #1

Introducción a Sistemas Inteligentes

Estudiante: Kristian Restrepo Osorio - krestrepoo@eafit.edu.co

Profesor: Marco Teran

Fecha: Septiembre 2025

1. Descripción de conceptos a través de LLMs

En esta sección se busca desarrollar conocimiento sobre los conceptos presentados posteriormente. En el documento anexo "*Prompts y Notas*" se puede evidenciar el proceso llevado a cabo con los LLMs para la generación de estos resultados.

- ***Big Data***: Conjunto de datos tan grandes y complejos que no pueden ser procesados con herramientas tradicionales, caracterizados por volumen (cantidad masiva de datos), velocidad (rapidez con la que se generan y procesan) y variedad (diferentes tipos de datos: estructurados, no estructurados y semiestructurados) [1].
- ***Machine Learning (ML)***: Rama de la inteligencia artificial que permite a los sistemas aprender patrones a partir de datos y mejorar su desempeño con la experiencia, sin ser programados explícitamente. Utiliza diferentes algoritmos para lograr esto [2].
- ***Inteligencia Artificial (IA)***: Disciplina que busca crear sistemas capaces de realizar tareas que requieren inteligencia humana. Estas tareas incluyen el aprendizaje, el razonamiento, la percepción, la comprensión del lenguaje natural y la resolución de problemas [3].
- ***Ciencia de Datos (Data Science)***: Campo interdisciplinario que combina estadística, programación y conocimiento del dominio para extraer información valiosa de datos complejos estructurados y no estructurados, buscando interpretar y analizar los mismos [4].
- ***Deep Learning***: Subárea del ML que utiliza redes neuronales profundas (con muchas capas), inspiradas en el cerebro humano, para reconocer y aprender patrones complejos en grandes volúmenes de datos, como en imágenes, texto, audio y más [5].
- ***Minería de Datos (Data Mining)***: Proceso (habitualmente dentro del Big Data) de explorar y analizar grandes conjuntos de datos para descubrir patrones ocultos, relaciones y tendencias útiles. Se apoya en la estadística, el machine learning y las bases de datos [6].
- ***Inteligencia de Negocios (Business Intelligence, BI)***: Estrategias y herramientas que transforman datos en información útil para apoyar la toma de decisiones empresariales. Su proceso se basa en la recopilación, integración, análisis y presentación de la información [7].

- **Estadística:** Ciencia que recopila, organiza, analiza, interpreta y presenta datos para obtener conclusiones y apoyar la toma de decisiones. Es la columna vertebral de todos los campos anteriores, ya que provee el rigor matemático para el análisis [8].

2. Diagrama de relación entre conceptos con Mermaid.js

Esta sección tiene como intención **diagramar las relaciones** que existen entre los **conceptos** de la sección anterior, utilizando herramientas como *Mermaid.js* junto a **LLMs** para la generación del mismo. En el documento anexo "*Prompts y Notas*" se puede evidenciar el proceso llevado a cabo con los LLMs para la generación de estos resultados.

El **diagrama** representa de manera clara las relaciones entre los principales conceptos: la **Estadística** aparece como base metodológica que nutre a la **Ciencia de Datos**, la **Minería de Datos** y el **Machine Learning**; el **Big Data** funciona como la fuente masiva de información que alimenta esas disciplinas y habilita entrenamientos complejos como el **Deep Learning**; la **Ciencia de Datos** integra metodologías y algoritmos; la **Minería de Datos** se centra en descubrir patrones; el **Machine Learning** y su especialización en **Deep Learning** permiten construir **modelos predictivos**; y todo ello se articula dentro de la **Inteligencia Artificial** para finalmente generar valor en la **Inteligencia de Negocios**, apoyando la **toma de decisiones**.

El resultado obtenido tiene sentido con respecto a lo que veíamos anteriormente, ya que refleja la **jerarquía lógica**: desde **fundamentos matemáticos** y **fuentes de datos**, pasando por **técnicas de análisis** y **aprendizaje**, hasta la **generación de valor empresarial**.

Además, el **proceso de iteración** con *DeepSeek*, *ChatGPT* y *Claude* durante más de una hora fue valioso: permitió **refinar las relaciones**, **mejorar la organización visual** y asegurar que el **diagrama** realmente represente la forma en que estos conceptos se interconectan en el campo del **aprendizaje de máquina** y la **analítica de datos**. En el documento anexo de "*Prompts y Notas*" se puede evidenciar el proceso llevado a cabo.

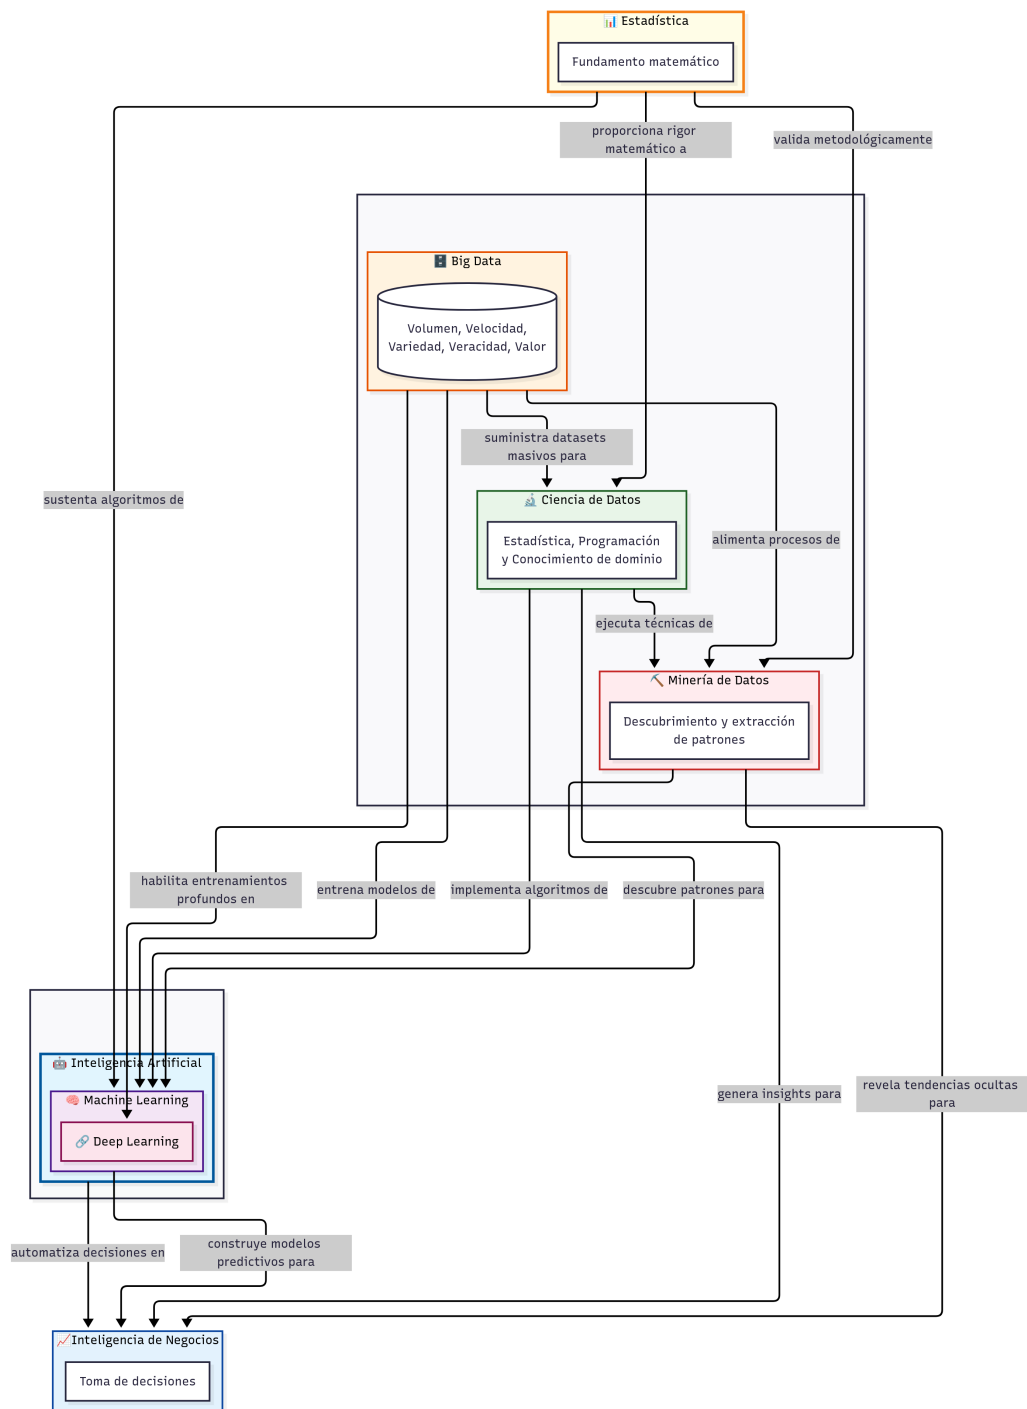


Figure 1: Diagrama de relaciones entre conceptos

3. Video reciente con aplicación interesante de IA

El video [9] presenta una aplicación de **IA multimodal** que combina visión por computador y modelos de lenguaje para buscar dentro de un video y generar resúmenes automáticos. La herramienta extrae fotogramas clave y transcripciones, los procesa con un **modelo de lenguaje grande (LLM)** y genera respuestas o resúmenes a partir de consultas en lenguaje natural.

De esta forma, se puede preguntar directamente al sistema cosas como “¿De qué trata este video?” o “Muéstrame la parte donde se habla de tal tema”, y la IA localiza y resume los segmentos relevantes. Esta tecnología resulta especialmente útil porque soluciona el problema del tiempo y esfuerzo que implica revisar contenido audiovisual de manera manual, permitiendo acceder a la información esencial de forma rápida y precisa.

4. ¿Qué son los *Transformers*?

Esta sección busca definir ciertos elementos relacionados con los *Transformers* a través del uso de LLMs. En el documento anexo “*Prompts y Notas*” se puede evidenciar el proceso llevado a cabo con los LLMs para la generación de estos resultados.

a) Ideas principales de su funcionamiento.

Los **transformers** son una arquitectura de red neuronal introducida en el artículo “*Attention Is All You Need*” por Vaswani et al. en 2017 [10]. Sus ideas principales incluyen:

- **Mecanismo de atención autoasistida (Self-Attention):** Permite que cada token en una secuencia interactúe con todos los demás tokens directamente, calculando **puntuaciones de atención** que determinan cuánto debe “prestar atención” a cada parte de la entrada.
- **Arquitectura encoder-decoder:** El *encoder* procesa la entrada y genera representaciones ricas y contextualizadas, mientras que el *decoder* genera la salida token por token utilizando la información del encoder.
- **Procesamiento paralelo:** A diferencia de las RNNs que procesan secuencias paso a paso, los transformers procesan **todas las posiciones simultáneamente**, permitiendo un entrenamiento más eficiente.

- **Atención multi-cabeza (*Multi-Head Attention*):** Ejecuta múltiples mecanismos de atención en paralelo, permitiendo al modelo capturar **diferentes tipos de relaciones** en los datos.

b) **Aplicaciones.**

Los transformers han permitido avances significativos en múltiples dominios [11]:

- **Procesamiento de Lenguaje Natural (*NLP*):** Traducción automática, generación de texto, resumen automático, análisis de sentimientos, sistemas de pregunta-respuesta y corrección gramatical.
- **Visión por computadora:** CLIP (contrastive language-image pre-training), DETR (DEtection TRansformer) para detección de objetos, ViT (Vision Transformer) para clasificación de imágenes.
- **Bioinformática:** Predicción de estructuras de proteínas (AlphaFold 2) y análisis de secuencias genéticas.
- **Sistemas de recomendación:** Modelado de preferencias de usuarios basado en historiales de interacción.

c) **Grandes Modelos de Lenguaje (LLMs) y su relación con transformers.**

Los LLMs son modelos de lenguaje a escala masiva que utilizan arquitecturas basadas en transformers [12]. Su relación es directa: los LLMs escalan el número de parámetros y datos de entrenamiento sobre esta arquitectura para adquirir capacidades de comprensión y generación de lenguaje a gran escala.

d) **Cómo se entrena un LLM conversacional.**

El entrenamiento de un LLM conversacional consta de varias fases complementarias [13]:

1. **Pre-entrenamiento no supervisado:**
 - **Objetivo:** Aprender representaciones generales del lenguaje.
 - **Datos:** Miles de millones de documentos de texto diverso.
 - **Tarea:** Predicción de tokens (*language modeling*).
 - **Duración:** Semanas o meses con clusters de GPUs/TPUs.
2. **Fine-tuning supervisado:**
 - **Objetivo:** Adaptar el modelo a conversaciones.
 - **Datos:** Conversaciones humanas ejemplares.
 - **Técnicas:** *Instruction tuning*, *dialog tuning*.
3. **Alineamiento con preferencias humanas (RLHF):**

- **Objetivo:** Hacer que las respuestas sean útiles, honestas e inofensivas.
 - **Proceso:** Recolección de datos, entrenamiento de un modelo de recompensa y optimización por refuerzo.
 - **Algoritmos:** PPO (*Proximal Policy Optimization*), DPO (*Direct Preference Optimization*).
4. **Técnicas de optimización:**
- *Mixed precision training*
 - *Gradient checkpointing*
 - *Model parallelism*
 - *Data parallelism*
5. **Evaluación e iteración:**
- **Métricas:** Perplexity, BLEU, ROUGE, evaluaciones humanas.
 - **Pruebas:** Evaluación en múltiples dominios y tareas.

5. Uso de un LLM para resolver problemas de programación

Para la resolución de los ejercicios se utilizó **ChatGPT-5** como asistente de programación. El modelo permitió escribir, depurar y optimizar las soluciones, garantizando la corrección de los resultados. En todos los casos se alcanzó un puntaje de **100%** en la plataforma de evaluación, para los 3 ejercicios planteados en el último módulo del curso. En el documento anexo "*Prompts y Notas*" se puede evidenciar el proceso llevado a cabo con los LLMs para la generación de estos resultados.

5.1. Ejercicio 1: Votación

Planteamiento. Dada una lista de votos (nombres), imprimir el ganador o EMPATE si el máximo recuento se repite.

Estrategia. Conteo con diccionario; luego se calcula el máximo y se verifica si hay más de un candidato con ese valor.

Solución (Python).

```
num_entradas = int(input().strip())
candidatos = {}

for _ in range(num_entradas):
    nombre = input().strip()
    candidatos[nombre] = candidatos.get(nombre, 0) + 1
```

```

max_votos = max(candidatos.values())
ganadores = [nombre for nombre, votos in candidatos.items() if votos == max_voto]
if len(ganadores) > 1:
    ganadores[0] = "EMPATE"

print(ganadores[0])

```

Resultados y discusión. El LLM propuso una solución directa y eficiente ($O(n)$). Pasó todos los casos. Se cuidó el manejo de espacios con `strip()` y la lógica de empate con `len(ganadores) > 1`.

Evidencia. Figura 2 es una captura de pantalla donde se muestra el resultado con **100% de aciertos** en la plataforma.

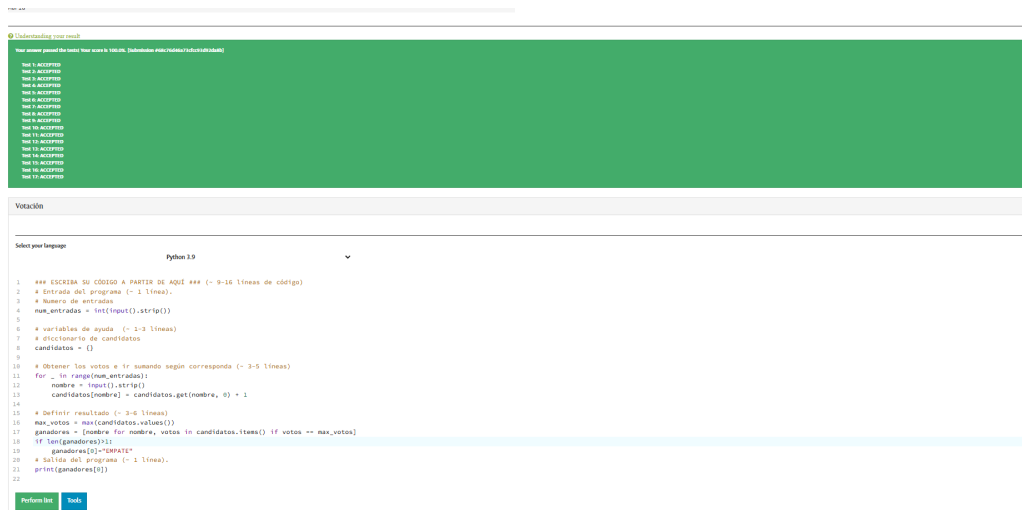


Figure 2: Resultado del ejercicio de diccionario con 100% de aciertos al resolver con el uso de LLMs

5.2. Ejercicio 2: Semejanza de textos

Planteamiento. Dadas dos frases, imprimir en líneas separadas: (1) el número de palabras compartidas y (2) el número de palabras únicas entre ambas.

Estrategia. Uso de conjuntos: compartidas con la intersección $A \cap B$ y únicas con la *diferencia simétrica* $A \Delta B$.

Solución (Python).

```

listado_a = set(input().split())

```



```

listado_b = set(input().split())

compartidas = len(listado_a & listado_b)
unicas = len(listado_a ^ listado_b)

print(compartidas)
print(unicas)

```

Resultados y discusión. Inicialmente el LLM usó la unión $A \cup B$ para el segundo valor, lo que provocó salidas mayores a las esperadas. Tras iterar, se corrigió a diferencia simétrica (\wedge en Python), alcanzando **100%** de aciertos. La lección fue verificar cuidadosamente la operación de conjuntos requerida y validar con los ejemplos.

Evidencia. Figura 3 es una captura de pantalla con el puntaje de **100% completado** tras la corrección.

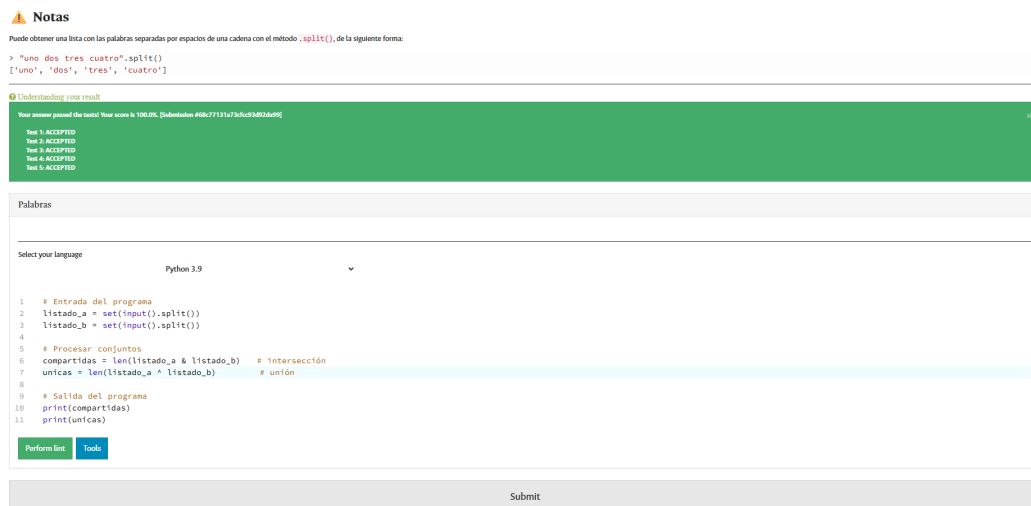


Figure 3: Resultado del ejercicio de conjuntos con 100% de aciertos al resolver con el uso de LLM

5.3. Ejercicio 3: Producto punto

Planteamiento. Dados dos vectores de enteros con igual dimensión, calcular su producto punto.

Estrategia. Lectura de ambas líneas como listas de enteros y uso de `zip` con suma de productos.

Solución (Python).

```
vector_u = list(map(int, input().strip().split()))
vector_v = list(map(int, input().strip().split()))

producto_punto = sum(u * v for u, v in zip(vector_u, vector_v))

print(producto_punto)
```

Resultados y discusión. Solución concisa, lineal en el tamaño del vector y sin complicaciones. El LLM produjo el enfoque estándar (map + zip), alcanzando **100%** de aciertos en los casos de prueba.

Evidencia. Figura 4 es una captura de pantalla mostrando el resultado con **100% completado**.

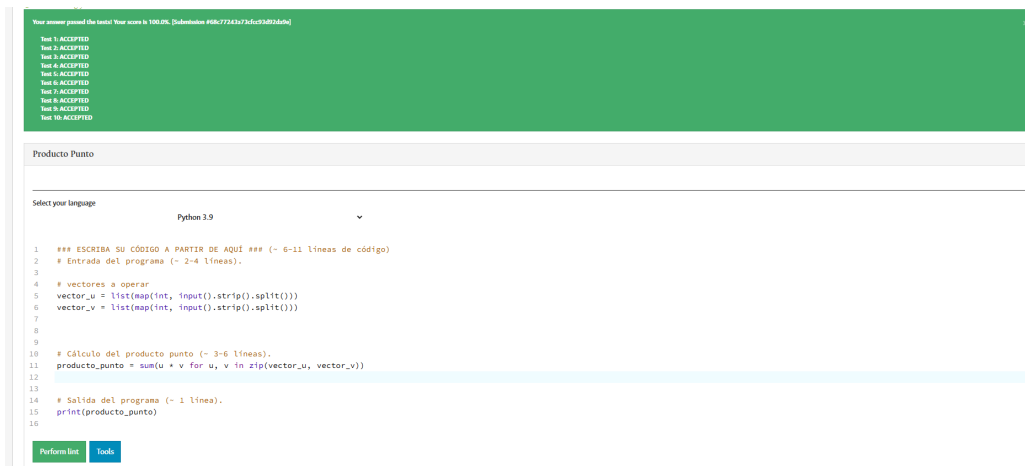


Figure 4: Resultado del ejercicio de operaciones entre listas con 100% de aciertos al resolver con el uso de LLM

Conclusión. El uso de **ChatGPT-5** permitió llegar rápido a soluciones correctas y legibles. La única corrección necesaria fue conceptual (unión vs. diferencia simétrica) en el ejercicio de conjuntos; con una breve iteración se solucionó. El contexto amplio brindado por la plataforma permitió cerrar los tres ejercicios con éxito total y con evidencia de **100% de logro**.

6. Uso de un LLM (ChatGPT) en una tarea reciente (investigación de usuarios)

En esta sección se busca detallar como los LLMs nos permiten resolver tareas de diferentes contextos, siendo este caso relacionado con una tarea de

investigación de usuarios utilizando ChatGPT (5). En el documento anexo “*Prompts y Notas*” se puede evidenciar el proceso llevado a cabo con los LLMs para la generación de estos resultados.

- **Contexto.** En un curso reciente realicé una entrega sobre *investigación de usuarios*. A partir de una **visión consolidada de la persona usuaria** (necesidades, dolores, motivaciones y comportamientos al usar la aplicación), debía producir: (i) un **escenario** narrativo que describiera la interacción en un contexto concreto y (ii) un **storyboard** tipo cómic que ilustrara las acciones y emociones clave.
- **Método con LLM.** Proporcioné a un LLM la visión consolidada como *contexto*, pidiéndole primero que generara un **escenario coherente** y, después, que propusiera un **guion visual** en viñetas para el storyboard (títulos de escena, descripciones, foco emocional y resultado esperado por viñeta). Con esa guía, generé la imagen final del storyboard.

6.1. Escenario propuesto (texto retornado por LLM)

Anasol está estudiando para una entrega importante de su maestría. Tenía un bloque de dos horas reservado para avanzar en la lectura crítica de un artículo, pero a mitad de la sesión recibe una llamada urgente de su familia. Al colgar, abre su asistente de estudio con IA, ingresa a su sesión de estudios actual y registra manualmente a través de lenguaje natural la interrupción indicando que su concentración se rompió y el tiempo planeado ya no podrá cumplirse.

El sistema procesa ese dato y de inmediato le propone una reorganización automática de su horario: divide el bloque restante en tareas más cortas y sugiere comenzar con una actividad ligera vinculada a su meta académica. Anasol tiene la posibilidad de aceptar o no dicha propuesta.

Anasol revisa la propuesta, nota que las entregas más próximas se mantienen en prioridad y acepta la reorganización con un click. Al terminar el nuevo bloque, el asistente le muestra un refuerzo positivo: “¡Bien! A pesar de la interrupción avanzaste un 15% en tu meta de esta semana”. Con esto, Anasol se siente motivada.

6.2. Storyboard



Figure 5: Storyboard generado a partir del escenario (viñetas con contexto, acción, emoción y resultado).

Los resultados fueron **muy satisfactorios** por dos motivos: (1) **eficiencia**: el LLM aceleró la redacción del escenario y la estructuración del guion visual, permitiéndome dedicar más tiempo a mejorar otros entregables del curso. (2) **calidad**: el storyboard final facilitó **comprender al usuario** y comunicar la propuesta de valor con claridad a pesar de que los integrantes del grupo no teníamos habilidades para dibujar.

Como limitación, validé manualmente que el tono y los detalles reflejaran fielmente la voz del usuario y el contexto del proyecto. En conjunto, el uso del LLM **mejoró la calidad** de la entrega y **optimizó el tiempo** dedicado a la tarea.

7. Argumentos a favor y en contra de la IAG

En esta sección se busca evaluar puntos positivos y negativos sobre la búsqueda de la inteligencia artificial general, resolviendo los puntos con LLMs como *ChatGPT-5* y *DeepSeek V3*. En el documento anexo "*Prompts y Notas*" se puede evidenciar el proceso llevado a cabo con los LLMs para la generación de estos resultados.

7.1. Argumentos a favor de la IAG

1. ***Avances exponenciales en tecnología:*** La Ley de Moore y el crecimiento exponencial del poder computacional (incluyendo la computación cuántica), junto con el avance del aprendizaje profundo, el almacenamiento de datos y la eficiencia algorítmica, sugieren que eventualmente se dispondrá del hardware necesario para emular la complejidad del cerebro humano.
2. ***Progreso continuo de la IA:*** Los campos del *machine learning* y el *deep learning* han avanzado a un ritmo sorprendente en la última década. Modelos de lenguaje grande (LLMs) como GPT-4 muestran destellos de razonamiento, creatividad y capacidad de generalización que, aunque no constituyen conciencia, apuntan hacia capacidades cognitivas más amplias y cercanas al comportamiento humano.
3. ***Interés y financiación global:*** El inmenso potencial económico y estratégico de una IAG crea una poderosa motivación para que estados, universidades y corporaciones inviertan billones de dólares en su investigación, acelerando así su desarrollo.
4. ***Imitación del cerebro humano:*** La neurociencia avanza en la comprensión de cómo funciona el cerebro. Teóricamente, si se logra entender su funcionamiento en detalle, se podría replicar su estructura (por ejemplo, a través de redes neuronales artificiales inspiradas en las biológicas) o incluso simularla por completo en una computadora (*uploading* mental).

7.2. Argumentos en contra de la IAG

1. ***Problemas éticos y de control:*** A medida que nos acerquemos a una IAG, surgirán cuestiones éticas de gran magnitud (riesgo existencial, control, derechos de la IA, uso masivo, pérdida de control). Esto podría llevar a que la sociedad decida detener o prohibir activamente su desarrollo, impidiendo su realización por razones no técnicas.
2. ***Costos energéticos y computacionales:*** Entrenar modelos cada vez más grandes ya es extremadamente costoso en términos de energía y hardware. Escalar estos requerimientos para alcanzar la IAG podría ser inviable con los recursos disponibles en el mundo.
3. ***Complejidad de la cognición humana:*** La inteligencia humana involucra emociones, intuición y experiencias contextuales difíciles de

modelar computacionalmente, lo que representa un obstáculo significativo para replicarla en sistemas artificiales.

8. Riesgos e implicaciones éticas de la Inteligencia Artificial

En esta sección se busca abordar cómo la inteligencia artificial trae consigo ciertos riesgos e implicaciones que se deben tener en consideración a la hora de hablar y crear sobre la misma. Para este análisis, se trataron dos puntos de vista: desde *ChatGPT-5* y *DeepSeek V3*. En el documento anexo "*Prompts y Notas*" se puede evidenciar el proceso llevado a cabo con los LLMs para la generación de estos resultados.

8.1. Riesgos principales

1. ***Pérdida de empleos y desigualdad social:*** La automatización puede desplazar a millones de trabajadores, generando desempleo estructural y ampliando la brecha económica.
2. ***Sesgos algorítmicos:*** Los modelos de IA reproducen o amplifican los prejuicios presentes en los datos de entrenamiento, lo que puede llevar a decisiones discriminatorias en ámbitos como justicia, salud o contratación.
3. ***Concentración de poder:*** El control de la IA por parte de unas pocas corporaciones o estados podría aumentar las asimetrías de poder globales y limitar la soberanía tecnológica de los países.
4. ***Seguridad y ciberataques:*** Los sistemas de IA pueden ser utilizados para generar ataques automatizados, manipulación de información o vulneración de infraestructuras críticas.
5. ***Opacidad y falta de explicabilidad:*** La dificultad de comprender el funcionamiento interno de modelos complejos plantea problemas de confianza, responsabilidad y transparencia.
6. ***Autonomía y dilemas éticos:*** Delegar decisiones sensibles (por ejemplo, en el ámbito militar o médico) a sistemas autónomos genera interrogantes sobre la responsabilidad moral y legal.

8.2. Implicaciones éticas

1. ***Necesidad de regulación:*** Es fundamental establecer marcos legales y normativos que limiten riesgos y garanticen un uso responsable.
2. ***Responsabilidad y rendición de cuentas:*** Definir quién es responsable de las acciones de una IA (desarrollador, usuario, empresa) resulta clave para la ética aplicada.
3. ***Derechos humanos y justicia social:*** El desarrollo de la IA debe respetar principios de equidad, inclusión y respeto por la dignidad humana.
4. ***Gobernanza internacional:*** Se requieren acuerdos multilaterales para evitar que la IA sea usada de manera dañina en contextos militares, políticos o económicos.

References

- [1] Gartner IT Glossary. (2012). *Big Data*. Recuperado de <https://www.gartner.com/en/information-technology/glossary/big-data>
- [2] Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.
- [3] Russell, S., & Norvig, P. (2020). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.
- [4] Davenport, T. H., & Patil, D. J. (2012). Data Scientist: The Sexiest Job of the 21st Century. *Harvard Business Review*.
- [5] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [6] Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
- [7] Howson, C. (2014). *Successful Business Intelligence: Unlock the Value of BI & Big Data*. McGraw-Hill.
- [8] Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). *Probability & Statistics for Engineers & Scientists* (9th ed.). Pearson.

- [9] NVIDIA. (2025). *Build a Video Search and Summarization Agent with NVIDIA AI Blueprint*. Recuperado de <https://developer.nvidia.com/blog/build-a-video-search-and-summarization-agent-with-nvidia-ai-blueprint>
- [10] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- [11] Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., & Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of the 2020 conference on empirical methods in natural language processing: system demonstrations*, 38-45.
- [12] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., & Amodei, D. (2020). Language models are few-shot learners. *Advances in neural information processing systems*, 33, 1877-1901.
- [13] Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., & Lowe, R. (2022). Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35, 27730-27744.